

Apprentissage Automatique

Rym Guibadj

LISIC, ULCO, EILCO

Apprentissage automatique

Quelques domaines de l'IA

- Représentation des connaissances
- Résolution de problèmes
- Reconnaissance de la parole
- Reconnaissance de l'écriture
- Reconnaissance des visages
- Robotique
- **Apprentissage automatique (artificiel)**

Apprentissage automatique

Définition

L'apprentissage automatique est un **sous-domaine de l'intelligence artificielle** qui se concentre sur le développement de techniques permettant d'**apprendre à partir de données**. L'objectif principal de l'apprentissage automatique est de permettre aux machines **d'acquérir des connaissances ou des compétences sans être explicitement programmées**.

Apprentissage automatique

- On dira qu'une machine **apprend** dès lors qu'elle change en fonction de données en entrée ou de réponses à son environnement de sorte à ce que **ses performance futures deviennent meilleures**
- L'objectif de l'apprentissage automatique est de **concevoir des programmes pouvant s'améliorer automatiquement avec l'expérience**

Pourquoi l'apprentissage automatique ?

- Certaines tâches ne sont bien définies que via un ensemble d'exemples
- Pour découvrir des relations importantes dans des données (fouille de données)
- Les machines peuvent ne pas fonctionner sur tous les environnements
- La quantité de connaissances disponibles à propos de certaines situations sont telles que le cerveau humain ne puisse les expliciter
- L'environnement change constamment

Des applications diverses :

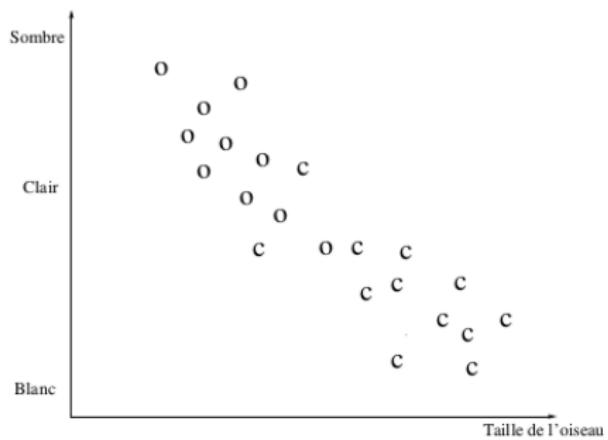
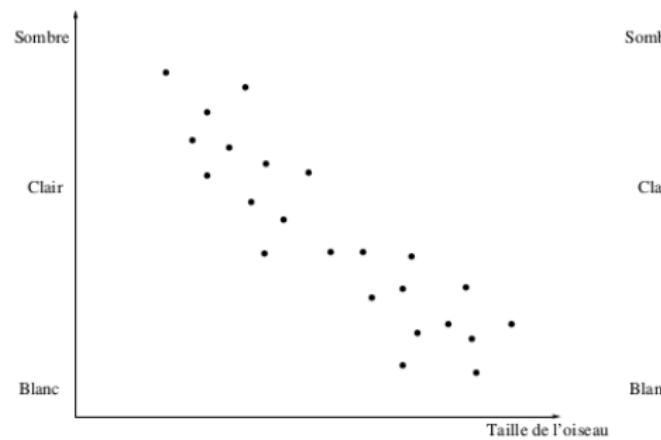
- Reconnaissance de la parole.
- Diagnostique médical.
- Moteurs de recherche.
- Les jeux.
- Conduite autonome.
- ...

Exemple d'apprentissage :

- Imaginons un étang sur lequel nagent des oies et des cygnes (nous admettons qu'il n'y a pas d'autres oiseaux dans cette région).
- Deux personnes arrivent dont l'un est expert et l'autre débutant.
- Le débutant souhaite apprendre à distinguer une oie d'un cygne. Il doit se contenter de mesurer ce qui lui paraît caractéristique : le niveau de gris du plumage et la taille de la bête.

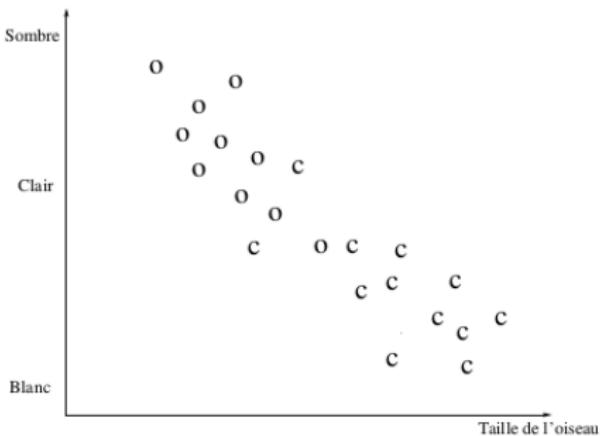
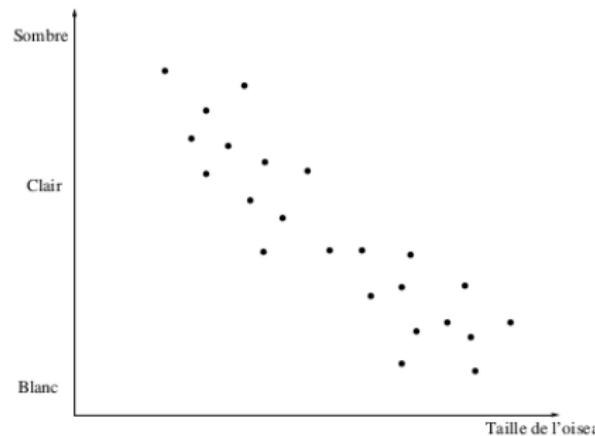
Exemple d'apprentissage :

- Le premier graphique représente les mesures de chaque oiseau prise par l'amateur
- Le second graphique représente les mêmes oiseaux étiquetés par l'expert



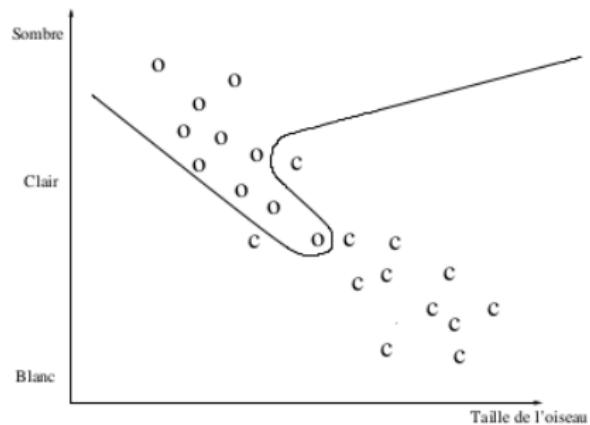
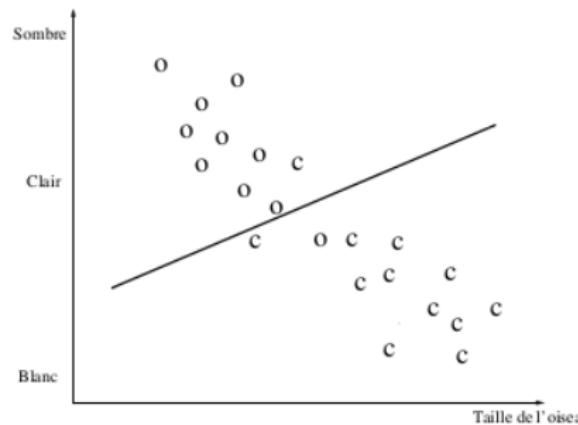
Exemple d'apprentissage :

- Il faut maintenant que l'amateur trouve une règle permettant de séparer les exemples en minimisant l'erreur.



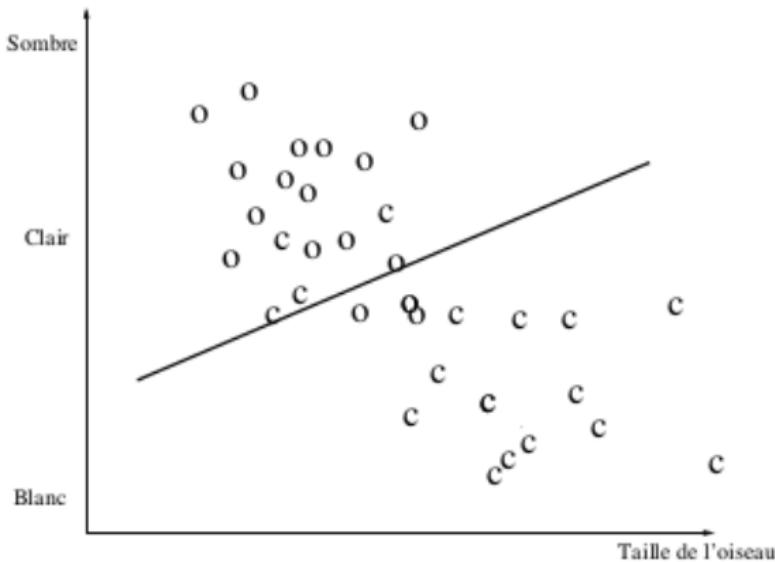
Exemple d'apprentissage :

- Une règle de décision simple et une règle de décision complexe pour séparer les oies des cygnes.



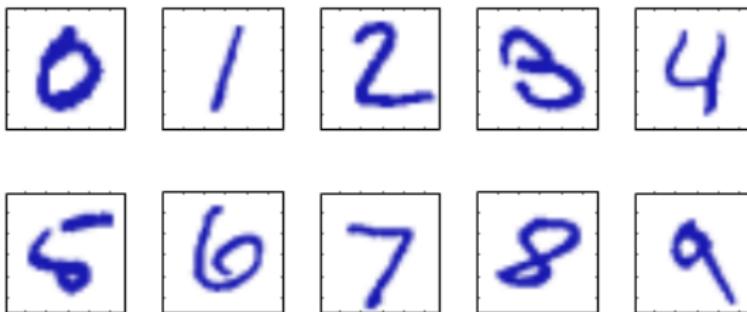
Exemple d'apprentissage :

- Le test de la règle simple sur d'autres oiseaux.



Exemple d'apprentissage :

Comment reconnaître des caractères manuscrits



- **Par énumération de règles** : trop fastidieux, difficile de couvrir tous les cas.
- **En donnant à l'ordinateur la capacité d'apprendre** : laisser l'ordinateur faire des essais et apprendre de ces erreurs.

Données d'entraînement et généralisation

On fournit à l'algorithme d'apprentissage des **données d'entraînements**

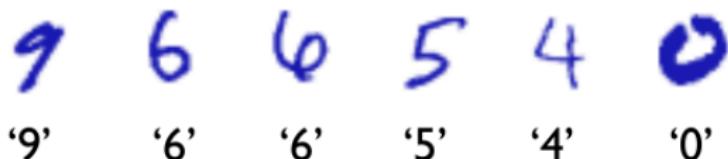
9 6 6 5 4 0
‘9’ ‘6’ ‘6’ ‘5’ ‘4’ ‘0’

L'algorithme retourne un programme capable de **généraliser** à de nouvelles données

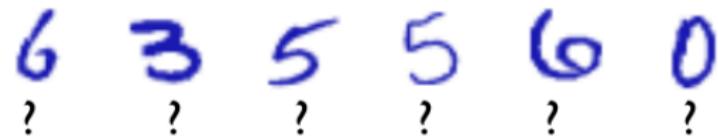
6 3 5 5 6 0
? ? ? ? ? ?

Données d'entraînement, généralisation et modèle

On note l'**ensemble d'entraînement** : $\mathcal{D} = \{(x_1, y_1), \dots, (x_N, y_N)\}$. On appelle x_i une **entrée** et y_i la **cible**.



Le «programme» généré par l'algorithme d'apprentissage $f(x)$ est appelé **un modèle** capable de généraliser à de nouvelles données.



Ensemble de tests

On utilise un ensemble de test D_{test} pour mesurer la performance de généralisation de notre modèle $f(x)$

6 3 5 5 6 0
'6' '3' '5' '5' '6' '0'

Types d'apprentissage :

- **Apprentissage supervisé** : il ya une cible à prédire

$$\mathcal{D} = \{(x_1, y_1), \dots, (x_N, y_N)\}$$

- Chaque exemple est associé à une étiquette
- Objectif : prédire l'étiquette de chaque donnée
- Le système apprend à classer les données

- **Apprentissage non supervisé** : cible n'est pas fournie

$$\mathcal{D} = \{x_1, \dots, x_N\}$$

- Les exemples ne sont pas étiquetés
- Objectif : trouver une structure aux données
- Le système apprend une classification des données

Types d'apprentissage :

- **Apprentissage par renforcement**

- Les exemples sont (parfois) associés à une récompense ou une punition
- Objectif : trouver les actions qui maximisent les récompenses
- Le système apprend une politique de décision

Types d'apprentissage :

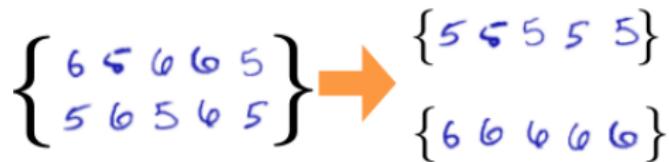
Apprentissage supervisé : il ya une cible à prédire

- **classification** : la cible est une classe $y \in \{1, \dots, K\}$. Exemple : reconnaissance de caractères
 - x : vecteur des intensités de tous les pixels de l'image
 - y : identité du caractère
- **régression** : la cible est un nombre réel $y \in R$. Exemple : prédiction de la valeur d'une action à la bourse
 - x : vecteur contenant l'information sur l'activité économique de la journée
 - y : valeur d'une action à la bourse le lendemain

Types d'apprentissage :

Apprentissage non supervisé : cible n'est pas fournie.

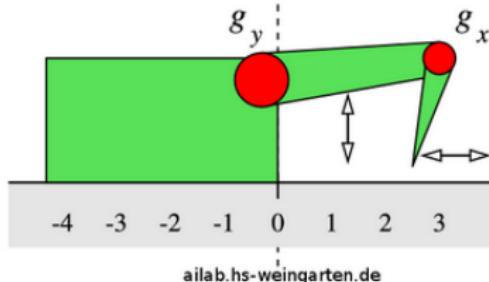
- Partitionnement / *clustering*
- Exemple : partitionnement des caractères manuscrits



Types d'apprentissage :

Apprentissage par renforcement

- Exemple : robot motorisé qui avancent sur différents types de sols
 - Observe les effets de ses actions
 - Déduit de ses observations la qualité de ses actions
 - Améliore ses actions futures



	1	2	3	4	5
1	0	0	0	0	0
2	0 0	0 0	0 0	0 0	0 0
3	-31 0	32 -29 0	-65 4 27 0	43 0 0 -47	0 0 0 16 0 0 0
4	-50 0	-66 -5 -52 0	-47 0 -43 54 0	-26 0 -26 0 0	-4 0 0 0 0
5	0 0	-47 -16 -71 0	0 -100 -62 0	0 -37 0 0	0 0 0 0

Types d'apprentissage :

Apprentissage par renforcement

- Exemple : configuration automatique de machines virtuelles d'un cluster de serveur linux dans un contexte de charge dynamique
 - 3 paramètres pertinents ont été choisis pour chacune des 3 VMs utilisées.
 - 3 actions sont possibles sur chaque paramètre : incrémentation, décrémentation ou invariance de celui-ci.
 - Les récompenses sont définies par le SLO (service level objectives) auquel on soustrait le temps de réponse.

Apprentissage supervisé

- Aussi appelé **analyse discriminante**
- Les données d'apprentissage sont étiquetées
 - Un **expert** ou **oracle** doit préalablement étiqueter des exemples.
- Le processus se passe en deux phases :
 - La **phase d'apprentissage** (*hors ligne*) : déterminer un modèle de données étiquetées
 - La **phase de test** (*en ligne*) : prédire l'étiquette d'une nouvelle donnée, connaissant le modèle préalablement appris.

Définition formelle

- Données d'apprentissage
 - N couples entrée sortie $(x_n, y_n)_{1 \leq n \leq N}$ avec $x_n \in X$ et $y_n \in Y$
 - On suppose que ces données sont tirées selon une loi (de probabilité) inconnue
- Objectif de l'apprentissage
 - déterminer une fonction de prédiction $f : X \rightarrow Y$ qui soit en accord avec le données d'apprentissage

Les différentes représentations

- Si f est une fonction continue on parle alors de **régression**.
- Si f est une fonction discrète on parle alors de **classification**.
- Si f est une fonction binaire on parle alors d'**apprentissage de concept**.

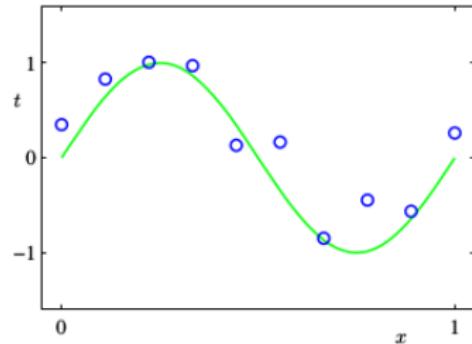
Méthodes d'apprentissage supervisé

Liste non exhaustive

- Régression polynomiale
- Les k plus proches voisins
- Arbre de décision
- Les réseaux de neurones
- Les machines à vecteur support
- etc.

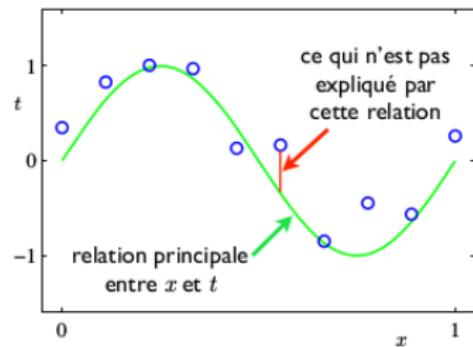
Régression

- Exemple simple : régression en une dimension ($1D$)
 - entrée : scalaire x
 - cible : scalaire y
- Données d'entraînements \mathcal{D} contiennent :
 - $(x_1, \dots, x_N)^T$
 - $(y_1, \dots, y_N)^T$
- **Objectif** : faire une prédiction \hat{y} pour une nouvelle entrée \hat{x}



Régression

- Exemple simple : régression en une dimension ($1D$)
 - entrée : scalaire x
 - cible : scalaire y
- Données d'entraînements \mathcal{D} contiennent :
 - $(x_1, \dots, x_N)^T$
 - $(y_1, \dots, y_N)^T$
- Objectif** : faire une prédiction \hat{y} pour une nouvelle entrée \hat{x}

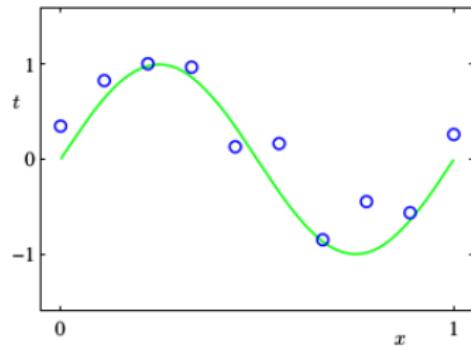


Régression polynomiale, modèle

- On va supposer qu'une bonne prédiction aurait une forme polynomiale

$$f(x, w) = w_0 + w_1 x + w_2 x^2 + \dots + w_M x^M$$

$$f(x, w) = \sum_{j=0}^M w_j x^j$$

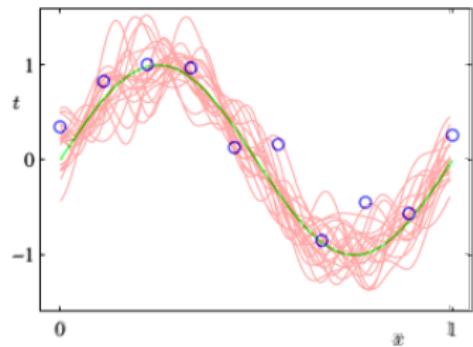


- $f(x, w)$ est notre modèle. Il représente nos hypothèses sur le problème à résoudre
 - La valeur de M représente le degré du polynôme.
 - Le vecteur $w = (w_1, w_2, \dots, w_M)$ représente les paramètres du modèle qu'on doit trouver

Régression : minimisation de perte (coût,erreur)

- Comment trouver w ? (problème d'apprentissage)
- On cherche le w^* qui minimise la somme de notre perte / erreur / coût sur l'ensemble d'entraînement

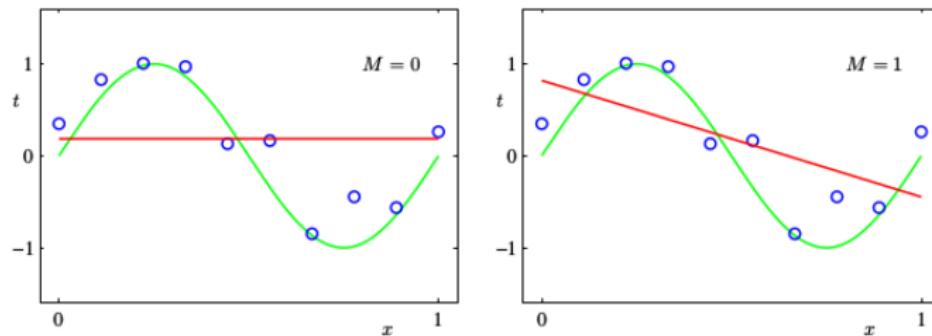
$$E(w) = \frac{1}{2} \sum_{n=1}^N \{f(x_n, w) - y_n\}^2$$



- Un algorithme d'apprentissage résoudrait ce problème : trouver w^* à partir des données

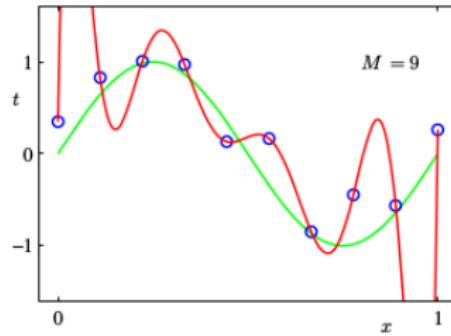
Régression : sous-apprentissage

- Comment choisir M (le degré du polynôme) ?
 - De trop petites valeurs auront une grande perte sur l'ensemble d'entraînement : situation de **sous-apprentissage**



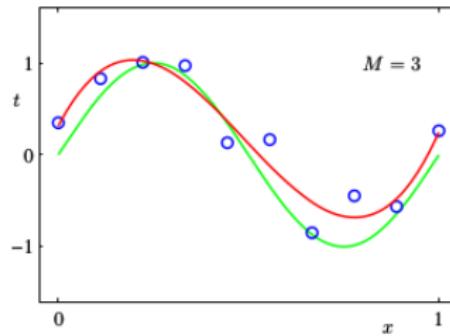
Régression : sur-apprentissage

- Comment choisir M (le degré du polynôme) ?
 - De trop grandes valeurs vont seulement apprendre l'ensemble d'entraînement "par coeur" : situation de **sur-apprentissage**
 - Apprendre à prédire ce que n'est pas prévisible à partir de x seulement (ex. du bruit)



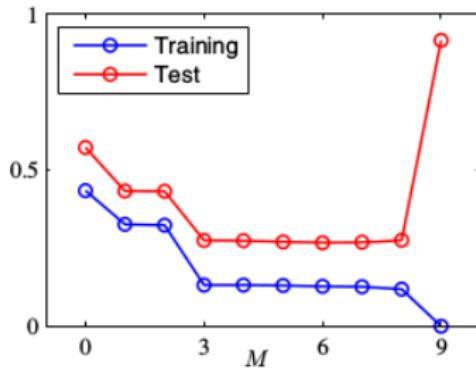
Régression : sélection de modèle

- Comment choisir M (le degré du polynôme) ?
 - On voudrait une valeur intermédiaire qui permet de retrouver la tendance générale de la relation entre x et y , sans le bruit
 - c'est ce qui va permettre de bien généraliser à de nouvelles entrées !
 - trouver cette meilleure valeur de M s'appelle de la **sélection de modèle**.
 - Il existe différentes techniques pour trouver le meilleur M .



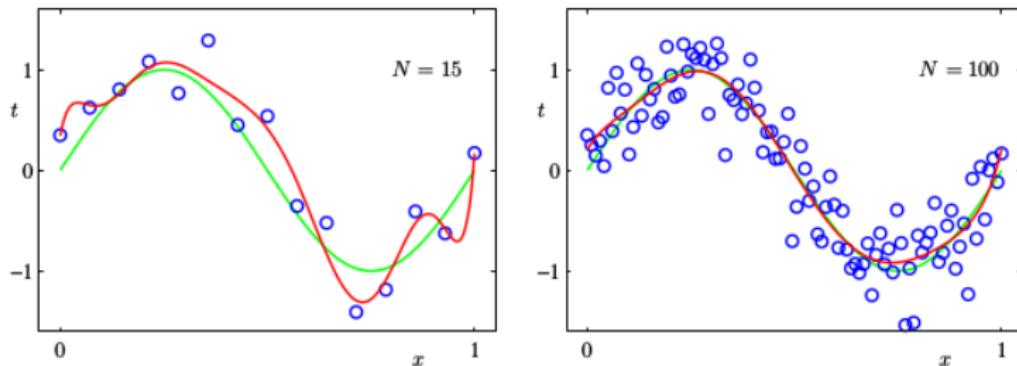
Régression : capacité d'un modèle, performance

- La **capacité** d'un modèle est son aptitude à apprendre "par coeur". Exemple : plus M est grand, plus le modèle a de capacité.
- Plus la capacité est grande, plus la différence entre l'erreur d'entraînement et l'erreur de test augmente.
- En régression, l'erreur sur tout un ensemble est souvent mesurée par la racine de la moyenne des erreurs au carré $E_{RMS} = \sqrt{2E(w^*)/N}$



Régression : généralisation vs. quantité de données

- Plus la quantité de données d'entraînement augmente, plus le modèle entraîné va bien généraliser



Régression : régularisation

- Comment utiliser un grand M avec peu de données
- **Régularisation** : on réduit la capacité autrement
 - On pénalise la somme des carrés des paramètres

$$\tilde{E}(x) = \frac{1}{2} \sum_{n=1}^N \{f(x_n, w) - y_n\}^2 + \frac{\lambda}{2} \|w\|^2$$

- où $\|w\|^2 = w^T w = w_0^2 + w_1^2 + \dots + w_M^2$

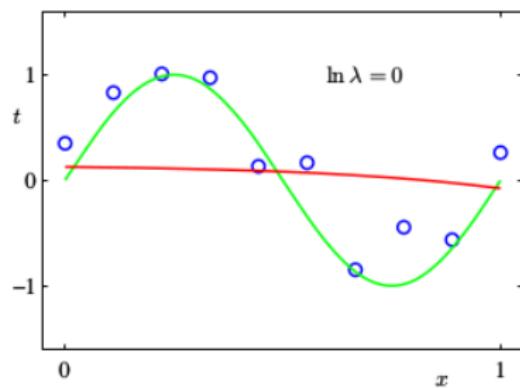
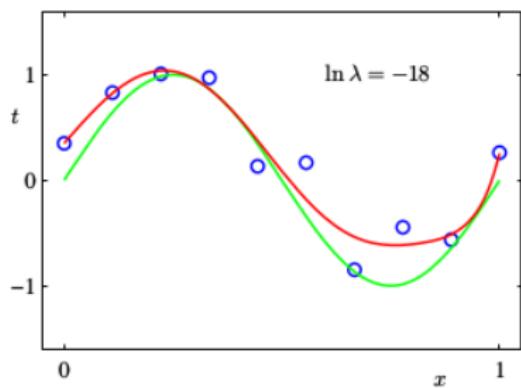
Régression : régularisation

- Valeurs des paramètres w^* pour différents M , sans régularisation

	$M = 0$	$M = 1$	$M = 3$	$M = 9$
w_0^*	0.19	0.82	0.31	0.35
w_1^*		-1.27	7.99	232.37
w_2^*			-25.43	-5321.83
w_3^*			17.37	48568.31
w_4^*				-231639.30
w_5^*				-231639.30
w_6^*				640042.26
w_7^*				-1061800.52
w_8^*				1042400.18
w_9^*				-557682.99
w_{10}^*				125201.43

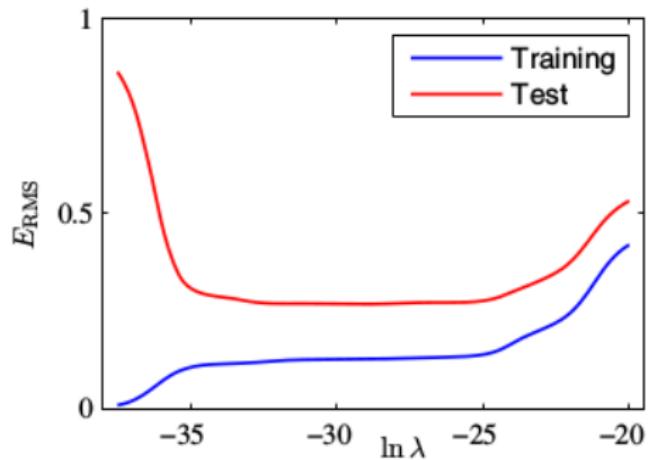
Régression : régularisation

- Plus la régularisation est forte, moins le modèle sera flexible (donc il aura moins de capacité)



Régression : régularisation

- Comme M , la force de la régularisation a une influence sur l'erreur d'entraînement et de test



Régression : sélection de modèle

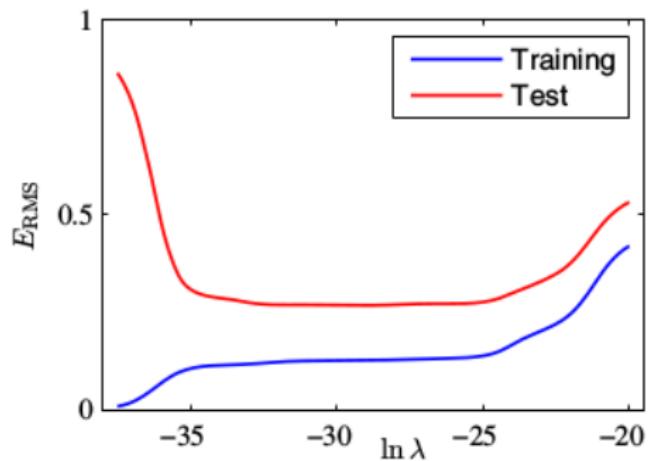
- Soit l'algorithme d'apprentissage qui optimise

$$\tilde{E}(x) = \frac{1}{2} \sum_{n=1}^N \{f(w_n, w) - y_n\}^2 + \frac{\lambda}{2} \|w\|^2$$

- On appelle M et λ des **hyper-paramètres** : ils doivent être déterminés avant l'entraînement.
- La **sélection de modèle** est le choix de la valeur de ces **hyper-paramètres**.

Régression : hyper-paramètres

- Le choix des hyper-paramètres va influencer la performance sur de nouvelles données (test)



Régression : ensemble de validation

- Solution I : on réserve des données d'entraînement pour comparer différentes valeurs
 - garde la majorité pour l'ensemble d'entraînement \mathcal{D}_{train} (ex. 80%)
 - le reste, \mathcal{D}_{valid} (ex. 20%), servira à comparer les hyper-paramètres
- On appelle \mathcal{D}_{valid} **l'ensemble de validation**

Régression : algorithme de sélection de modèle

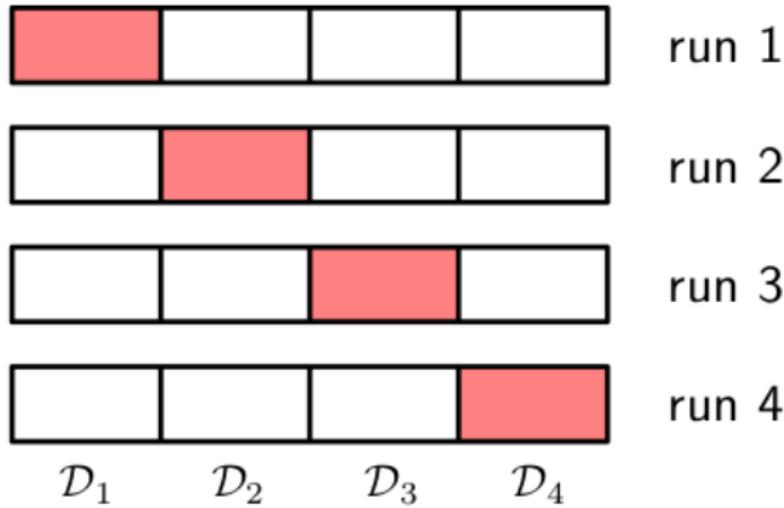
- Pour chaque valeur d'hyper-paramètres à comparer
 - obtenir un modèle entraîné à partir de \mathcal{D}_{train}
 - évaluer la performance du modèle sur \mathcal{D}_{valid}
- retourner le choix d'hyper-paramètres ayant donné le modèle avec la meilleure performance sur \mathcal{D}_{valid}

Régression : S-fold cross-validation

- Lorsqu'on a peu de données, 20% est trop peu pour estimer la performance de généralisation
- On pourrait répéter la procédure de séparation *train/valid* plus d'une fois
- **S-fold cross-validation** : divise les données en S portions différentes. Chaque portion est utilisée une fois en tant que \mathcal{D}_{valid}

Régression : S-fold cross-validation

- Exemple : $S = 4$



Régression : S-fold cross-validation

Sélection de modèle avec S-fold cross-validation

Pour $s = 1 \dots S$

Pour chaque valeur d'hyper-paramètres à comparer

obtenir un modèle entraîné à partir de $\mathcal{D}_{train} = \mathcal{D} \setminus \mathcal{D}_s$

évaluer la performance du modèle sur $\mathcal{D}_{valid} = \mathcal{D}_s$

retourner la valeur des hyper-paramètres ayant la meilleure performance moyenne sur les ensembles \mathcal{D}_{valid}

- Si $S = N$, on parle alors de méthode **leave-one-out**

Régression : S-fold cross-validation

- Comment déterminer la liste des valeurs d'hyper-paramètres à comparer ?
- recherche sur une grille
 - détermine une liste de valeur pour chaque hyper-paramètre
 - construit la liste de toutes les combinaisons possibles