

Repets (supervisé)

- Régression linéaire
 - ↳ Descente de gradient
 - Équation Normale
 - Regularisation
 - Équilibre biais-variance
 - Motivations statistiques (MLE / MAP)
- Classification
 - Modèle linéaire
 - Extension à plusieurs classes (1vs1, 1vs tous discriminant à plusieurs classes)
 - Régression logistique
 - Perceptrons
 - Réseaux de neurones (Formulation générale + Back propagation)

Aujourd'hui: Astuce du moyen / Méthode à moyen

$$l(\beta) = \frac{1}{N} \sum_{i=1}^N (t^{(i)} - \langle \beta, \tilde{x}^{(i)} \rangle)^2 \quad \tilde{x}^{(i)} = [1, x_1^{(i)}, \dots, x_D^{(i)}]$$

$\tilde{\phi}(x^{(i)})$ = vecteur de caractéristiques supplémentaires
(ex: polynomiales)

$$\hat{\beta} \leftarrow \beta + \frac{2N}{N} \sum_{i=1}^N (t^{(i)} - \langle \beta, \tilde{\phi}(x^{(i)}) \rangle) \tilde{\phi}(x^{(i)})$$

Ex
 $\tilde{x}^{(i)} \in \mathbb{R}^D \rightarrow \text{si } \tilde{\phi}(x^{(i)}) \text{ est composé de caractéristiques polynomiales de degré au max 3}$

$$\tilde{\phi}(x^{(i)}) = [1, x_1, x_2, \dots, x_D, x_1^2, x_1 x_2, \dots, x_D^2, x_1^3, x_1^2 x_2, x_1^2 x_3, \dots, x_D^3]$$

$$\dim \tilde{\Phi}(x^{(i)}) = 1 + D + D^2 + D^3$$

Supposons qu'on puisse écrire β comme une combinaison linéaire

$$\beta = \sum_{j=1}^N \lambda_j \tilde{\Phi}(x^{(j)})$$

terejours vrai: pour $\beta = 0$

$$\begin{aligned} \beta^{(k+1)} &= \sum_{j=1}^N \lambda_j \tilde{\Phi}(x^{(j)}) + \frac{2\gamma}{N} \sum_{j=1}^N (t^{(j)} - \sum_{i=1}^N \lambda_i \tilde{\Phi}(x^{(i)})^T \tilde{\Phi}(x^{(j)})) \tilde{\Phi}(x^{(j)}) \\ &= \sum_{j=1}^N \tilde{\Phi}(x^{(j)}) \left[\lambda_j + \frac{2\gamma}{N} (t^{(j)} - \sum_{i=1}^N \lambda_i \tilde{\Phi}(x^{(i)})^T \tilde{\Phi}(x^{(j)})) \right] \end{aligned}$$

$$N \ll D^d$$

$$\lambda_j^{(k+1)} = \lambda_j^{(k)} + \frac{2\gamma}{N} \left(t^{(j)} - \sum_{i=1}^N \lambda_i^{(k)} \tilde{\Phi}(x^{(i)})^T \tilde{\Phi}(x^{(j)}) \right)$$

$$\langle \tilde{\Phi}(x), \tilde{\Phi}(z) \rangle \text{ for } \tilde{\Phi}(x) = [1, x_1, x_2, \dots, x_D, \overbrace{x_1^2, x_1 x_2, \dots, x_D^2}^{x_1^3, x_1 x_2^2, \dots, x_D^3}]$$

$$= 1 + \sum_{i=1}^D x_i z_i + \sum_{i,j} x_i x_j z_i z_j + \sum_{i,j,k} x_i x_j x_k z_i z_j z_k$$

$$= 1 + \langle x, z \rangle + \langle x, z \rangle^2 + \langle x, z \rangle^3$$

$$\lambda_j^{(k+1)} \leftarrow \lambda_j^{(k)} + \frac{2y}{N} \left(t^{(j)} - \sum_{i=1}^N \lambda_i^{(k)} K(i, j) \right) \leftarrow$$

$K(i, j)$ = matrice moyenne dont l'entrée (i, j) correspond au produit scalaire entre les vecteurs $\tilde{\phi}(x^{(i)})$ et $\tilde{\phi}(x^{(j)})$
 (pas nécessairement connus explicitement)

Etant donné K , quelles sont les propriétés qui en font une "bonne" matrice pour l'apprentissage ?

Condition #1: Symétrique

Condition #2 : K semi-definite positive $K \geq 0$

$$z^T K z \geq 0 \Leftrightarrow K = \Phi \Phi^T \leftarrow$$

$\forall z$

suppose $K(i, j) = \tilde{\Phi}(x^{(i)})^T \tilde{\Phi}(x^{(j)})$

$$z^T K z = \sum_{i, j} z_i K(i, j) z_j = \sum_{i, j} z_i \tilde{\Phi}(x^{(i)})^T \tilde{\Phi}(x^{(j)}) z_j$$

$$= \sum_{i, j} z_i \sum_k \tilde{\Phi}_k(x^{(i)}) \tilde{\Phi}_k(x^{(j)}) z_j$$

$$= \sum_k \sum_i z_i \tilde{\Phi}_k(x^{(i)}) \sum_j z_j \tilde{\Phi}_k(x^{(j)})$$

$$= \sum_k \left(\sum_i z_i \tilde{\Phi}_k(x^{(i)}) \right)^2 \geq 0$$

Théorème de Mercer

K est une noyau valide si: symétrique et semi-défini positif

$$\text{Ex } K(x, z) = (x^T z)^2$$

$$= \left(\sum_{i=1}^d x_i z_i \right)^2 = \sum_{i,j} x_i x_j z_i z_j$$

$$= \tilde{\phi}(x)^T \tilde{\phi}(z) \text{ où}$$

$$\tilde{\phi}(x) = [x_1^2, x_1 x_2, \dots, x_d^2]$$

$$K(x, z) = (x^T z + c)^2 \quad c \geq 0$$

$$= c^2 + \left(\sum_i x_i z_i \right)^2 + 2c \sum_i x_i z_i$$

$$= C^2 + \sum_i \sum_j x_i x_j z_i z_j + \underbrace{2C \sum_i x_i z_i}_{\tilde{\Phi}(\lambda)^T \tilde{\Phi}(z)} = \tilde{\Phi}(\lambda)^T \tilde{\Phi}(z)$$

$$\tilde{\Phi}(x) = [C, x_1^2, x_1 x_2, \dots, x_d^2, \sqrt{2C}(x_1, x_2, \dots, x_d)]$$

$$k(x, z) = \exp\left(-\frac{\|x - z\|^2}{\sigma^2}\right) \leftarrow$$

$$y(x) = \beta^T \tilde{\Phi}(x)$$

$$= \sum_{i=1}^N \lambda_i^\infty \tilde{\Phi}(x^{(i)})^T \tilde{\Phi}(x)$$

$$= \sum_{i=1}^N \lambda_i^\infty k(x^{(i)}, x) = \sum_{i=1}^N \lambda_i^\infty \exp\left(-\frac{\|x^{(i)} - x\|^2}{\sigma^2}\right)$$

