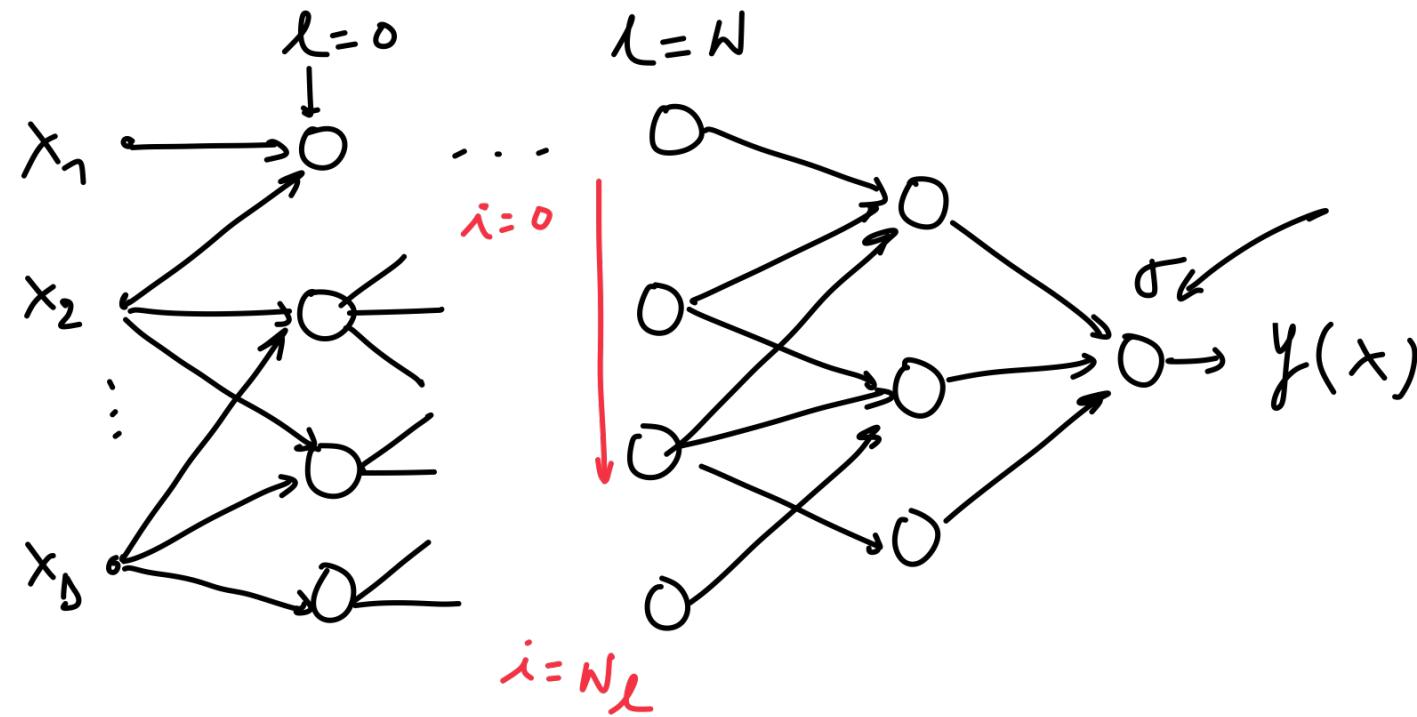


Réseau de Wendnes



→ Apprentissage du réseau via Maximum de vraisemblance

$$p(\{t(x^{(i)}) = t^{(i)}\}_{i=1}^N | \{x^{(i)}\}) = \prod_{i=1}^N p(t(x^{(i)}) = t^{(i)} | x^{(i)})$$

Et si fais-*c'* c'est le réseau lui-même qui est utilisé pour représenter $p(t(x^{(i)}) = t^{(i)} | x^{(i)})$

$$p(t(x^{(i)}) = 1 | x^{(i)}) = y(x^{(i)})$$

$$p(t(x^{(i)}) = 0 | x^{(i)}) = 1 - y(x^{(i)})$$

$$p(t(x^{(i)}) = t^{(i)} | x^{(i)}) = y(x^{(i)})^{t^{(i)}} (1 - y(x^{(i)}))^{1-t^{(i)}}$$

→ On peut ensuite entraîner le réseau en maximisant la log vraisemblance,

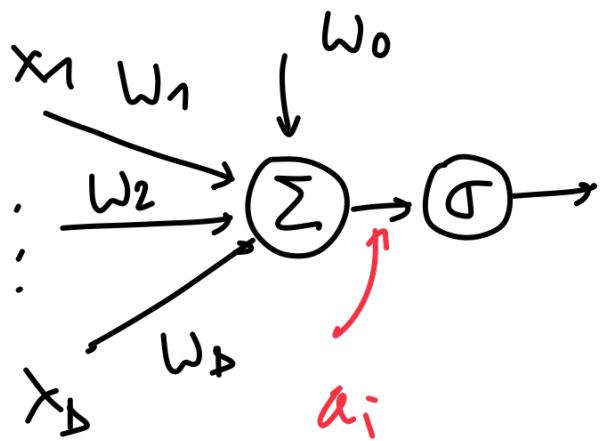
$$\max \log \prod_{i=1}^N p(t(x^{(i)}) = t^{(i)} | x^{(i)})$$

$$\max \log \prod_{i=1}^n y(x^{(i)})^{t^{(i)}} (1 - y(x^{(i)}))^{1-t^{(i)}}$$

$$\min J = - \sum_{i=1}^n t^{(i)} \log y(x^{(i)}) + (1-t^{(i)}) \log (1-y(x^{(i)}))$$

$\sigma(a_{\text{out}})$ $\sigma(a_{\text{out}})$

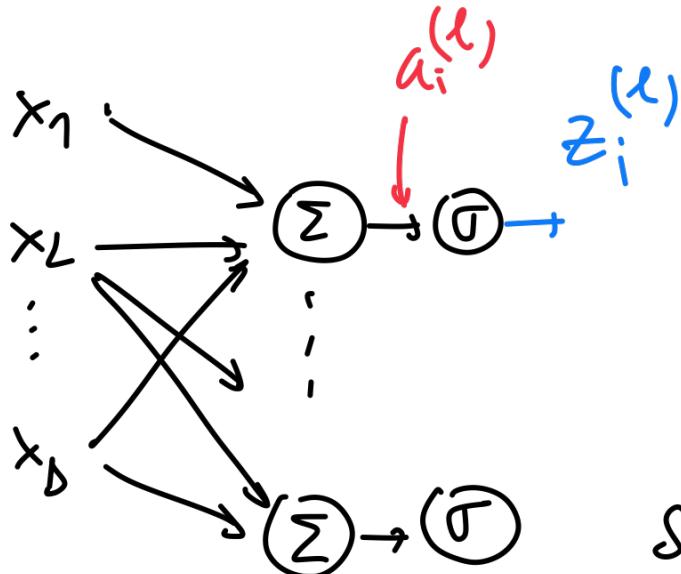
ENTROPIE BINNAIRE CROISÉE = J



$a_i^{(l)}$ = preactivation associé au neurone i de la couche l

$$a_i^{(l)} = \sum_{j=1}^{N_l} w_{ij}^{(l)} z_j^{(l-1)} + w_{i0}^{(l)}$$

$$z_j^{(l-1)} = \sigma(a_j^{(l-1)})$$



→ Objectif : obtenir les gradients

$$\frac{\partial J}{\partial w_{ij}^{(l)}}$$

Step 1 $\frac{\partial J}{\partial w_{ij}^{(l)}} = \frac{\partial J}{\partial a_i^{(l)}} \cdot \frac{\partial a_i^{(l)}}{\partial w_{ij}^{(l)}}$

gradient
par rapport

aux paramètres
du neurone i de
la couche l

Step 2 $= \delta_i^{(l)} z_j^{(l-1)}$

Step 2 $\delta_{\text{out}} = \frac{\partial J}{\partial a_{\text{out}}}$

$$\delta_{\text{out}} = \frac{\partial}{\partial a_{\text{out}}} \left\{ -t^{(l)} \log(\sigma(a_{\text{out}})) - (1-t^{(l)}) \log(1-\sigma(a_{\text{out}})) \right\}$$

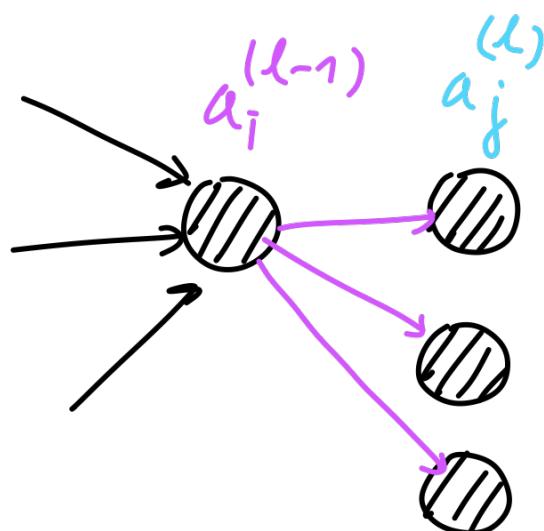
$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

$$\delta_{\text{out}} = -t^{(i)} \frac{\sigma'(a_{\text{out}})}{\sigma(a_{\text{out}})} - (1 - t^{(i)}) \frac{(-\sigma'(a_{\text{out}}))}{1 - \sigma(a_{\text{out}})}$$

$$\sigma'(x) = \frac{e^{-x}}{(1 + e^{-x})^2} = \left(\frac{1}{1 + e^{-x}}\right)\left(1 - \frac{1}{1 + e^{-x}}\right) = \sigma(x)(1 - \sigma(x))$$

$$\begin{aligned}\delta_{\text{out}} &= -t^{(i)}(1 - \sigma(a_{\text{out}})) + (1 - t^{(i)})\sigma(a_{\text{out}}) \\ &= \sigma(a_{\text{out}}) - t^{(i)}\end{aligned}$$

Step 3



chaque $a_i^{(l-1)}$ est utilisé par tous les neurones de la couche suivante (couche l)

$$\frac{\partial J}{\partial a_i^{(l-1)}} = \delta_i^{(l-1)} = \sum_{j=1}^{N_l} \frac{\partial J}{\partial a_j^{(l)}}$$

$$\delta_i^{(l-1)} = \sum_{j=1}^{N_l} \delta_j^{(l)}$$

$$\frac{\partial J}{\partial a_i^{(l)}}$$

pour le second facteur, en

utilisant la définition des préactivations

$$w_{ji}^{(l)} \sigma'(a_i^{(l-1)})$$

$$a_j^{(l)} = \sum_{i=1}^{N_{l-1}} w_{ji}^{(l)} \sigma(a_i^{(l-1)}) + w_{j0}^{(l)}$$

Step 3: à partir des $\delta_i^{(l)}$ obtenir les $\delta_i^{(l-1)}$ via

$$\delta_i^{(l-1)} = \sum_{j=1}^{N_l} \delta_j^{(l)} w_{ji}^{(l)} \sigma'(a_i^{(l-1)}) \quad (*)$$

Back propagation: (dévier avec $w_{ij}^{(l)}$ aléatoires)

- Pour un exemple $\{x^{(i)}, t^{(i)}\}$, propager l'exemple à travers tout le réseau et générer toutes les valeurs de pre et post activations $a_i^{(l)}, z_j^{(l)}$ pour toute couche l et tout neurone i

→ Calculer $\delta_{\text{out}} = y(x^{(i)}) - t^{(i)}$

→ Dériver tous les $\delta_i^{(l)}$ à partir de δ_{out} via (*)

→ Dériver les gradients via

$$\frac{\partial J}{\partial w_{ij}^{(l)}} = \delta_i^{(l)} z_j^{(l-1)}$$

→ Réaliser un pas dans la direction opposé au gradient

$$w_{ij}^{(l)} \leftarrow w_{ij}^{(l)} - \gamma \frac{\partial J}{\partial w_{ij}^{(l)}}$$