


Apprentissage supervisé $\{x^{(i)}, t^{(i)}\}_{i=1}^N$



→ Apprentissage : 2 approches : - Descente de gradient
- Résolution des équations normales

$$l(\beta) = \frac{1}{N} \sum_{i=1}^N \left(t^{(i)} - (\beta_0 + \beta_1 x_1^{(i)} + \dots + \underbrace{\beta_D x_D^{(i)}}_{=}) \right)^2$$


Descente de gradient : $\vec{\beta}^{(0)} \in \mathbb{R}^{D+1}$

fer à lui un MaxIker

$$\vec{\beta} \leftarrow \vec{\beta} - \eta \text{ grad } l(\beta)$$

Équations normales

$$\vec{\beta}_{OLS} = (\underline{\tilde{X}}^T \underline{\tilde{X}})^{-1} \underline{\tilde{X}}^T t$$



Pour D suffisamment grand, il existera toujours un modèle linéaire capable de "filtrer" les observations

→ ? $\tilde{X}^T \tilde{X}$ non inversible ? ex: quand certaines caractéristiques sont dépendantes.

$$\langle x, y \rangle = x^T y$$

→ Première solution: Gram-Schmidt

Démarrer avec $z_0 = z_0$ la première colonne de \tilde{X}


For $j = 1, \dots, D$

Calculer les coefficients $\hat{\gamma}_{lj} = \langle c_j, z_l \rangle / \langle z_l, z_l \rangle$

for $l = 0, \dots, j-1$

$$z_j = c_j - \sum_{l=0}^{j-1} \hat{\gamma}_{lj} z_l$$

$$\min_{\beta} \frac{1}{N} (\vec{t} - \underline{\underline{X}} \underline{\beta})^T (\vec{t} - \underline{\underline{X}} \underline{\beta}) = \frac{1}{N} \vec{r}^T \vec{r}$$



la solution de (*) peut être facilement calculé dans la base des vecteurs z_j via

$$\alpha_j = \frac{\langle \vec{t}, z_j \rangle / \langle z_j, z_j \rangle}{\alpha_j}$$

$$\begin{aligned} \text{On a } h_{\beta}(x) &= \sum_j \alpha_j z_j = \alpha_D z_D + \sum_{j=0}^{D-1} \alpha_j z_j \\ &= \underbrace{\alpha_D}_{c_D} + \dots + \sum_{j=0}^{D-1} \alpha_j z'_j \end{aligned}$$

$$\hat{\beta}_D = \alpha_D = \underbrace{\frac{\langle t, z_D \rangle}{\langle z_D, z_D \rangle}}$$



$$\{x^{(i)}, t^{(i)}\}_{i=1}^N$$

$$\{x^{(i)}, t^{(i) + \Delta}\}_{i=1}^N$$

$$\hat{\beta}_{OLS} = \underbrace{(\tilde{X}^T \tilde{X})^{-1}}_{\downarrow} \tilde{X}^T t$$


$$\begin{bmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_{D+1} \end{bmatrix}^{-1} = \begin{bmatrix} \lambda_1^{-1} & & \\ & \ddots & \\ & & \lambda_{D+1}^{-1} \end{bmatrix}$$

$$h_{\beta}(x) = \underbrace{\beta_0 + \beta_1 x_1 + \cdots + \beta_D x_D}_{\beta^T x}$$




$$\beta_{OLS}^1 = (\tilde{X}^\top \tilde{X})^{-1} \tilde{X}^\top t$$

$$\beta_{OLS}^2 = \underbrace{(\tilde{X}^\top \tilde{X})^{-1} \tilde{X}^\top}_{\text{ }} (t + \Delta)$$




(Sélection de caractéristiques)


Approche 2 : Sélection du meilleur sous ensemble




$$\sum_{k=1}^D \binom{D}{k} \text{ sous ensembles}$$



→ 2 étapes : Pour chaque sous ensemble, on entraîne le modèle sur D_{train} et on calcule l'erreur de prédiction sur D_{test}



Dans le cas où l'ensemble des observables est limité par k
 toute vers la validation croisée ($\leq K$ Compartiments)



1 Compartiment de test et $K-1$ compartiments d'entraînement

$$\text{erreur}_{CV} = \frac{1}{N} \sum_{i=1}^N (t^{(i)} - \bar{h}_\beta^{K(i)}(x^{(i)}))^2$$

$\bar{h}_\beta^{K(i)}$ = le modèle entraîné sur tous les compartiments sauf celui qui contient l'observation $\{x^{(i)}, t^{(i)}\}$

Approche #3 :

terme de fidélité aux données

$$L(\beta) = \frac{1}{N} \sum_{i=1}^N (t^{(i)} - (\beta_0 + \beta_1 x_1^{(i)} + \dots + \beta_D x_D^{(i)}))^2$$

penalité sur la complexité du modèle

$$+ \lambda \sum_{j=1}^D \beta_j^2$$

→ Modèle de Régression Ridge

(Regularization)

$\beta_1 \ \beta_2$ pénalité Ridge : $\beta_1^2 + \beta_2^2$

$$\min \ell(\beta) = \frac{1}{N} \sum_{i=1}^N (t^{(i)} - (\beta_0 + \beta_1 x_1^{(i)} + \beta_2 x_2^{(i)}))^2 + \lambda \sum_{j=1}^2 \beta_j^2$$


(formulation non contrainte)

$$\min \ell(\beta) = \frac{1}{N} \sum_{i=1}^N (t^{(i)} - (\beta_0 + \beta_1 x_1^{(i)} + \beta_2 x_2^{(i)}))^2$$

$$\sum_{j=1}^2 \beta_j^2 \leq t^2$$


(Formulation contrainte)

$$\beta_1^2 + \beta_2^2 \leq t^2$$




Approche 4: Regression LASSO

$$l(\beta) = \frac{1}{N} \sum_{i=1}^N (t^{(i)} - (\beta_0 + \beta_1 x_1^{(i)} + \dots + \beta_D x_D^{(i)}))^2 + \lambda \sum_{j=1}^D |\beta_j|$$



Désavantage :
forte dérivabilité





Min

$$\ell(\beta) = \frac{1}{N} \sum_{i=1}^N (t^{(i)} - (\beta_0 + \beta_1 x_1^{(i)} + \dots + \beta_D x_D^{(i)}))^2$$

t.g.

$$\sum_{j=1}^D |\beta_j| \leq t$$

LASSO



$$\|\vec{\beta}\|_2 = \sqrt{\sum_{j=1}^d \beta_j^2}$$

$$\|\vec{\beta}\|_1 = \sum_{j=1}^d |\beta_j|$$

$$\|\vec{\beta}\|_\infty = \max_j |\beta_j|$$


$$\|\vec{\beta}\|_p = \left(\sum_{j=1}^d \beta_j^p \right)^{1/p} \rightarrow \text{norme } l_p$$

A chaque norme l_p on associe la boule l_p
 parmi lesquelles la boule l_1

$$\sum_{j=1}^d |\beta_j| \leq t$$

l_2 la boule l_2

$$\sum_{j=1}^d |\beta_j|^2 \leq t$$



Ridge → pour rappel : Fonction somme des résidus Carrés

$$l(\beta) = \frac{1}{N} (\vec{E} - \underline{\tilde{X}}\vec{\beta})^T (\vec{E} - \underline{\tilde{X}}\vec{\beta}) + \lambda \vec{\beta}^T \vec{\beta}$$

$$\rightarrow l(\beta) = \frac{1}{N} \vec{E}^T \vec{E} - \frac{1}{N} \vec{t}^T \underline{\tilde{X}}\vec{\beta} - \frac{1}{N} \vec{\beta}^T \underline{\tilde{X}}^T \vec{E} + \frac{1}{N} \vec{\beta}^T \underline{\tilde{X}}^T \underline{\tilde{X}}\vec{\beta} + \lambda \vec{\beta}^T \vec{\beta}$$

$$\text{grad } l(\beta) = -\frac{2}{N} \underline{\tilde{X}}^T \vec{E} + \frac{2}{N} \underline{\tilde{X}}^T \underline{\tilde{X}}\vec{\beta} + 2\lambda \vec{\beta}$$

$$\text{grad } l(\beta) = 0 \Rightarrow (\underline{\tilde{X}}^T \underline{\tilde{X}} + \lambda I) \vec{\beta} = \underline{\tilde{X}}^T \vec{E}$$

$$\vec{\beta}_{\text{Ridge}} = (\underline{\tilde{X}}^T \underline{\tilde{X}} + \lambda I)^{-1} \underline{\tilde{X}}^T \vec{E}$$

Problème avec OLS c'est que lorsqu'on a de petits valeurs propres, l'inverse sera grande.

$$\begin{array}{c} \tilde{X}^T \tilde{X} v = \xi v \quad \rightarrow (\tilde{X}^T \tilde{X} + \lambda I) v \\ \hline \hline \end{array}$$

$$\begin{array}{c} \tilde{X}^T \tilde{X} \vec{v} + \lambda \vec{v} = \xi \vec{v} + \lambda \vec{v} \\ \hline \hline \end{array}$$

$$= (\xi + \lambda) \vec{v}$$

Soit (ν, ξ) une

fonction vecteur propre

valeur propre de $\tilde{X}^T \tilde{X}$

$\tilde{X}^T \tilde{X}$ est semi-définie positive \rightarrow toutes les valeurs propres sont positives ou nulles

Héme si ξ est petit pour que J suffisamment grand,
 on peut contrôler l'amplitude de l'inverse, et donc des
 coefficients de régression.

Supposons que les données sont générées via

$$\underbrace{t^{(i)}}_{\text{modèle}} = \beta_0 + \beta_1 x_1^{(i)} + \dots + \beta_D x_D^{(i)} + \varepsilon^{(i)}, \quad \varepsilon^{(i)} \sim N(0, \sigma^2)$$

$\varepsilon^{(i)}$ indépendants

$$q(\varepsilon^{(i)}) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(\varepsilon^{(i)})^2}{2\sigma^2}\right)$$

identiquement
distribués


$$t^{(i)} \sim N(\beta_0 + \beta_1 x_1^{(i)} + \dots + \beta_D x_D^{(i)}, \sigma^2)$$

$$\hat{p}(t^{(i)} | \beta) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(t^{(i)} - (\beta_0 + \beta_1 x_1^{(i)} + \dots + \beta_D x_D^{(i)}))^2}{2\sigma^2}\right)$$


$$p(\{t^{(i)}\}_{i=1}^N | \beta) = \prod_{i=1}^N p(t^{(i)} | \beta)$$

$$= \prod_{i=1}^N \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(t^{(i)} - (\beta_0 + \beta_1 x_1^{(i)} + \dots + \beta_D x_D^{(i)}))^2}{2\sigma^2}\right)$$

$$\vec{\beta} = \arg \max_{\beta} p(\{t^{(i)}\}_{i=1}^N | \beta)$$



$$\vec{\beta} = \arg \max \log \left(\prod_{i=1}^N \frac{1}{\sqrt{2\pi}\sigma} \exp \left(-\frac{(t^{(i)} - (\beta_0 + \beta_1 x_1^{(i)} + \dots + \beta_D x_D^{(i)}))^2}{2\sigma^2} \right) \right)$$



Fonction de log vraisemblance

$$\vec{\beta} = \arg \max_{\beta} \sum_{i=1}^N \log \left(\frac{1}{\sqrt{2\pi}\sigma} \right) - \sum_{i=1}^N \frac{(t^{(i)} - (\beta_0 + \beta_1 x_1^{(i)} + \dots + \beta_D x_D^{(i)}))^2}{2\sigma^2}$$

$$\vec{\beta}_{MLE} = \arg \min_{\beta} \sum_{i=1}^N (t^{(i)} - (\beta_0 + \beta_1 x_1^{(i)} + \dots + \beta_D x_D^{(i)}))^2$$

→ le Modèle de régression linéaire entraîné via la minimisation de la fonction de coût donnée par la somme des carrés des résidus correspond à l'estimation de moindre moindre.

Aucune hypothèse sur le Modèle (i.e. coefficients) → MLE
 $p(t^{(i)} | \beta)$

Maximum a Posteriori: $p(\beta | t^{(i)})$

Règle de Bayes: $p(B|A) = \frac{p(A|B)p(B)}{p(A)}$

$$\text{MAP} : \underline{p(\beta | t^{(i)})} = \frac{\underline{p(t^{(i)} | \beta)} p(\beta)}{p(t^{(i)})} \rightarrow \text{ne dépend pas de } \beta$$

probabilité à posteriori.

Etant donné $p(\beta | t^{(i)})$ on peut définir $\hat{\beta}_{\text{MAP}}$ comme l'estimateur qui maximise cette probabilité

$$\hat{\beta}_{\text{MAP}} = \underset{\beta}{\operatorname{argmax}} \underline{p(t^{(i)} | \beta)} \circled{p(\beta)}$$


A priori sur le modèle

S. $p(\beta)$ est une forme on récupère le PMLE.

→ Un premier exemple d'a priori sur β consistant à favoriser des coefficients qui soit pour la plupart

Proches de 0 \rightarrow

$$p(\beta) = \prod_{j=1}^d p(\beta_j) = \prod_{j=1}^d \frac{1}{\sqrt{2\pi}\xi} \exp\left(-\frac{\beta_j^2}{2\xi^2}\right)$$



\log

$$p(\beta | \{t^{(i)}\}_{i=1}^N) \propto \prod_{i=1}^N \frac{1}{\sqrt{2\pi}\sigma} \exp\left(\frac{t^{(i)} - (\beta_0 + \beta_1 x_1^{(i)} + \dots + \beta_d x_d^{(i)})}{2\sigma^2}\right)$$

$$\times \prod_{j=1}^d \frac{1}{\sqrt{2\pi}\xi} \exp\left(-\frac{\beta_j^2}{2\xi^2}\right)$$

$$\hat{\beta}_{MAP} = \underset{\beta}{\operatorname{argmax}} \quad p(\beta | \{t^{(i)}\}_{i=1}^N)$$

$$\vec{\beta}_{MAP} = \arg \max_{\beta} \log(p(\vec{y} | \{t^{(i)}\}_{i=1}^N))$$

$$= \sum_{i=1}^N \log \left(\frac{1}{\sqrt{2\pi}\sigma} \right) - \frac{(t^{(i)} - (\beta_0 + \beta_1 x_1^{(i)} + \dots + \beta_D x_D^{(i)}))^2}{2\sigma^2}$$

$$+ \sum_{j=1}^D \log \left(\frac{1}{\sqrt{2\pi}\xi} \right) - \frac{\beta_j^2}{2\xi^2}$$


constants for
regression & β

$$\vec{\beta}_{MAP} = \arg \max_{\beta} - \sum_{i=1}^N (t^{(i)} - (\beta_0 + \beta_1 x_1^{(i)} + \dots + \beta_D x_D^{(i)}))^2 / 2\sigma^2$$

$$- \sum_{j=1}^D \beta_j^2 / 2\xi^2$$

$$= \underset{\beta}{\operatorname{argmax}} \frac{1}{2\sigma^2} \left(- \sum_{i=1}^N (t^{(i)} - (\beta_0 + \beta_1 x_1^{(i)} + \dots + \beta_D x_D^{(i)}))^2 \right. \\ \left. - \frac{\lambda \sigma^2}{2} \sum_{j=1}^D \beta_j^2 \right)$$

Formulation Ridge




$$\frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{x^2}{2\sigma^2}\right)$$

$$\frac{1}{2\lambda} \exp\left(\frac{-|x|}{\lambda}\right)$$

Dans le cas de la distribution de Laplace, le Maximum a posteriori retrouve l'estimateur LASSO

Équilibre "b'aï-variaile"

Erreur quadratique moyenne $\{x, t(x)\}$



$$\begin{aligned}
 \text{MSE}(x) &= \mathbb{E}_{\mathcal{D}_i} \{ (t(x) - h_{\mathcal{D}_i}(x))^2 \} \quad h_{\mathcal{D}_i}(x) = \text{modèle} \\
 &\quad \text{entraîné sur} \\
 &= \mathbb{E}_{\mathcal{D}_i} \{ (t(x) - \mathbb{E}_{\mathcal{D}_i} h_{\mathcal{D}_i}(x) + \mathbb{E}_{\mathcal{D}_i} h_{\mathcal{D}_i}(x) - h_{\mathcal{D}_i}(x))^2 \} \quad \text{les données de} \\
 &\quad \mathcal{D}_i
 \end{aligned}$$

$$= \mathbb{E}_{\mathcal{D}_i} \left\{ (t(x) - \mathbb{E}_{\mathcal{D}_i} h_{\mathcal{D}_i}(x))^2 \right\} \leftarrow \text{bias}^2$$

$$+ \mathbb{E}_{\mathcal{D}_i} \left\{ (\mathbb{E}_{\mathcal{D}_i} h_{\mathcal{D}_i}(x) - h_{\mathcal{D}_i}(x))^2 \right\} \leftarrow \text{Variance}$$

$$+ \underbrace{2 \mathbb{E}_{\mathcal{D}_i} \left\{ (t(x) - \mathbb{E}_{\mathcal{D}_i} h_{\mathcal{D}_i}(x)) (\mathbb{E}_{\mathcal{D}_i} h_{\mathcal{D}_i}(x) - h_{\mathcal{D}_i}(x)) \right\}}$$

$$= 2 \left(t(x) - \mathbb{E}_{\mathcal{D}_i} h_{\mathcal{D}_i}(x) \right) \mathbb{E}_{\mathcal{D}_i} \left\{ (\mathbb{E}_{\mathcal{D}_i} h_{\mathcal{D}_i}(x) - h_{\mathcal{D}_i}(x)) \right\}$$

$$\mathbb{E}_{\mathcal{D}_i} h_{\mathcal{D}_i}(x) - \mathbb{E}_{\mathcal{D}_i} h_{\mathcal{D}_i}(x)$$

Complexité augmente \rightarrow variance \nearrow
bias \searrow

Complexité diminue \rightarrow variance \searrow
bias \nearrow

